Векторная квантизация диффузионных трансформеров

Егор Подъяблонский

МГУ, факультет ВМК

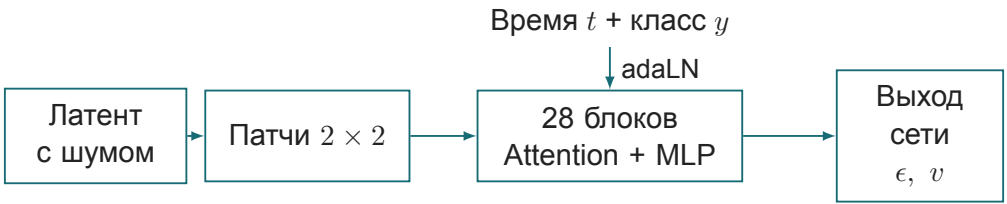
Научный руководитель: Айбек Аланов

Цель Уменьшить память для хранения весов DiT, сохранив качество изображений.

Квантизация — замена весов модели компактным приближением.

Как устроен DiT

DiT шаг за шагом удаляет шум из изображения.



ϵ — предсказание шума; v — выход головы дисперсии.

Квантуем веса 140 матриц внутри этих блоков.

В наших экспериментах генерация занимает **50 шагов**.

Несколько кодбуков для весов модели

Кодбук — небольшая таблица векторов.

Вместо хранения всех весов храним таблицы и индексы.

$$\underbrace{\widehat{w} = sC[a]}_{\text{один кодбук}} \qquad \longrightarrow \qquad \underbrace{\widehat{w} = s\sum_{m=1}^{4} C_m[a_m]}_{\text{четыре кодбука}}.$$

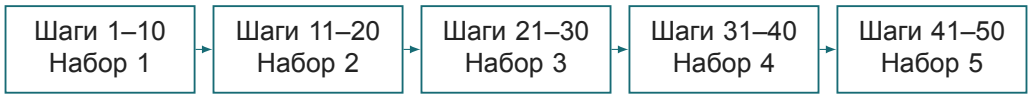
Идея: сумма нескольких векторов позволяет гибче приближать группу весов.

Хранение весов DiT: 32 $\rightarrow$ 4.15 бита/параметр.

Первая гипотеза: кодбуки для разных времён

50 шагов генерации делим на **5 окон по 10 шагов**.

Для каждого окна выбираем свой набор кодбуков.



Наборы кодбуков	бит/парам.	FID↓
Один общий	4,15	15,64
Пять временных	4,26	15,69

Выигрыша в FID нет, памяти требуется больше.

Вторая гипотеза: выход всей сети

Послойная калибровка

$$\mathcal{L}_{\text{layer}} = \sum_{\ell} \|X_\ell W_\ell - X_\ell \widehat{W_\ell}\|_F^2.$$

Калибровка по выходу всей сети

$$\mathcal{L}_{\text{rec}} = \text{MSE}(\epsilon_Q, \epsilon_T) + 0{,}1\,\text{MSE}(v_Q, v_T).$$

Q — квантованная сеть, T — исходная DiT.

500 обновлений кодбуков. Объём хранения не меняется.

Калибровка по выходу сети улучшила FID

10 000 изображений, 50 шагов DDPM

Меньше FID — ближе к реальным изображениям.

Модель	бит/парам.	FID↓
Исходная DiT	32	6,10
Послойная квантизация	4,15	15,40
Калибровка по выходу	**4,15**	**7,81**

FID ниже на 49,3% при прежней битности.