Векторная квантизация диффузионных трансформеров

Егор Подъяблонский

МГУ, факультет ВМК

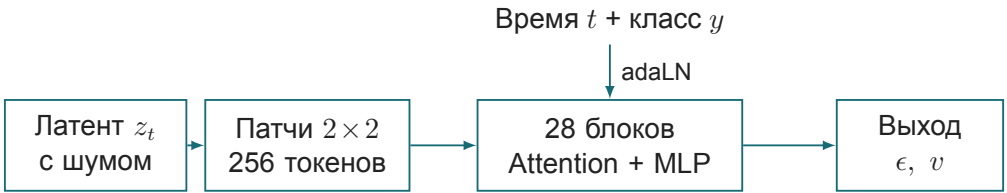
Научный руководитель: Айбек Аланов

Задача Сквантовать DiT: сократить память весов с небольшой потерей качества генерации.

Основа Представлять группы весов суммой элементов нескольких кодбуков.

Как устроен DiT-XL/2

DiT предсказывает шум на каждом шаге диффузии.



Квантуем: 140 матриц внутри блоков.

Оцениваем: FID↓ при заданной битности.

ImageNet256; ϵ — шум, v — сырой выход головы дисперсии.

Peebles, Xie. Scalable Diffusion Models with Transformers, 2023.

Несколько кодбуков для одной группы весов

Кодбук — небольшая таблица векторов.

Идея: сумма нескольких кодовых векторов даёт более гибкое приближение весов, чем один вектор.

$$\underbrace{\widehat{w} = sC[a]}_{\text{один кодбук}} \qquad \longrightarrow \qquad \underbrace{\widehat{w} = s\sum_{m=1}^{4} C_m[a_m]}_{\text{четыре кодбука}}.$$

В каждом кодбуке 256 векторов длины 8.

Четыре 8-битных индекса на 8 весов: **4 бита/вес**.

С кодбуками и остальными весами: **4.15 бита/параметр**.

Основа — аддитивная квантизация VQDM (Egiazarian et al., 2024).

Первая гипотеза: кодбуки для разных времён

На разных шагах меняются входы и чувствительность DiT.

Идея: выделить свой набор кодбуков каждому из 5 окон.

Наборы кодбуков	Обновления	бит/парам.	FID↓
Один общий	1 000	4,150	15,644
Пять временных	5×200	4,259	15,695

Временная специализация не дала выигрыша в FID.

Локальная ошибка уменьшилась, память выросла.

Историческое парное сравнение: 10k, DDPM50, CFG 1,5.

Вывод относится к этому способу учёта времени.

Вторая гипотеза: изменить loss калибровки

Послойно: приближать выход каждой матрицы, $\|XW - X\widehat{W}\|^2$.

Глобально: приближать выход всей исходной DiT:

$$\mathcal{L}_{\text{rec}} = \text{MSE}(\epsilon_Q, \epsilon_T) + 0{,}1\,\text{MSE}(v_Q, v_T).$$

Q — квантованная модель, T — исходная; входы совпадают.

Обновляем только значения кодбуков; индексы и масштабы фиксированы. **Битность сохраняется.**

500 шагов Adam, 10^{-5}, batch 16; 4 000 латентов для обучения,

1 000 отложено. Общие кодбуки для всех времён.

Калибровка по выходу сети улучшила FID

ImageNet256, 10 000 изображений, DDPM50, CFG 1,5

Одинаковые классы, парные шумы, MSE VAE; метрики ADM

Модель	бит/парам.	FID↓	sFID↓
Исходная DiT	32	6,10	21,68
Послойный VQDM	4,15	15,40	27,60
VQDM + выход сети	**4,15**	**7,81**	**23,37**

FID ниже на 49,3% при прежней битности.

Итог: временные кодбуки не помогли; глобальный loss помог.

Разрыв с FP: 1,72 FID. Recall: $0{,}7115 \rightarrow 0{,}6770$.

Один запуск. Таблица временных кодбуков — другая выборка.