Векторная квантизация диффузионных трансформеров

Егор Подъяблонский

МГУ, факультет ВМК

Научный руководитель: Айбек Аланов

Цель Уменьшить память для хранения весов DiT, сохранив качество изображений.

Квантизация — замена весов модели компактным приближением.

Как устроен DiT

DiT шаг за шагом удаляет шум из изображения.



Квантуем веса 140 матриц внутри этих блоков.

В наших экспериментах генерация занимает **50 шагов**.

Несколько кодбуков для весов модели

Кодбук — небольшая таблица векторов.

Вместо хранения всех весов храним таблицы и индексы.

$$\underbrace{\widehat{w} = sC[a]}_{\text{один кодбук}} \qquad \longrightarrow \qquad \underbrace{\widehat{w} = s\sum_{m=1}^{4} C_m[a_m]}_{\text{четыре кодбука}}.$$

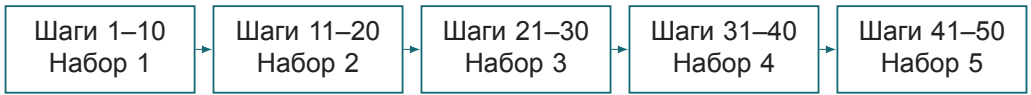
Идея: сумма нескольких векторов позволяет гибче приближать группу весов.

Хранение весов DiT: 32 $\rightarrow$ 4.15 бита/параметр.

Первая гипотеза: кодбуки для разных времён

50 шагов генерации делим на **5 окон по 10 шагов**.

Для каждого окна выбираем свой набор кодбуков.



Наборы кодбуков	бит/парам.	FID↓
Один общий	4,15	15,64
Пять временных	4,26	15,69

Выигрыша в FID нет, памяти требуется больше.

Вторая гипотеза: выход всей сети

Послойная калибровка

Приближаем выход каждого слоя отдельно.

Калибровка по выходу всей сети

Приближаем ответ исходной DiT на том же входе.

Совместно настраиваем кодбуки всех слоёв.

500 обновлений кодбуков. Объём хранения не меняется.

Калибровка по выходу сети улучшила FID

10 000 изображений, 50 шагов DDPM

Меньше FID — ближе к реальным изображениям.

Модель	бит/парам.	FID↓
Исходная DiT	32	6,10
Послойная квантизация	4,15	15,40
Калибровка по выходу	**4,15**	**7,81**

FID ниже на 49,3% при прежней битности.

В наших опытах временные кодбуки не дали выигрыша, а калибровка по выходу всей сети помогла.