Дистилляция кодбуков квантованной DiT

Егор Подъяблонский

МГУ, факультет ВМК

Научный руководитель: Айбек Аланов

Цель Улучшить генерацию при прежней битности.

Гипотеза Подгонка кодбуков под выход исходной сети снижает FID после послойной квантизации.

Модель и обоснование

DiT-XL/2 Диффузионный трансформер для ImageNet256.

VQDM Группы весов заменяются суммами элементов кодбуков:

$$\widehat{w} = s \sum_{m=1}^{4} C_m[a_m], \qquad K = 256, \quad d = 8.$$

Индексы: номинально 4 бита на квантованный вес.

Вся DiT с кодбуками и остальными параметрами: **4.15 бита/параметр**.

DiT: Peebles, Xie, 2023. VQDM: Egiazarian et al., 2024.

VQDM уже использует глобальную дистилляцию для U-Net. Здесь проверяется её перенос на DiT с обучением только кодбуков.

Подгонка под выход всей сети

Одинаковые зашумлённый латент z_t, время t и класс y подаются исходной и квантованной DiT.

$$\mathcal{L}_{\text{KD}} = \underbrace{\text{MSE}(\epsilon_Q, \epsilon_T)}_{\text{предсказание шума}} + 0{,}1 \underbrace{\text{MSE}(v_Q, v_T)}_{\text{сырой variance-выход}} .$$

Обучаются: значения кодбуков всех 140 матриц блоков.

Фиксированы: индексы, масштабы, смещения и остальные параметры.

Размер хранения сохраняется: формы массивов и FP16-точность кодбуков не меняются.

Это fine-tuning по ответам учителя. Уменьшение KD-loss само по себе не гарантирует улучшения FID.

Эксперимент и критерии качества

KD500: Adam, 10^{-5}, batch 16, 500 обновлений.

4 000 ImageNet-латентов для обучения, 1 000 отложено.

Фиксированная проба из 96 пар для выбора checkpoint.

Во время обучения t выбирается из исходной сетки 1 000 времён.

Оценка: по 10 000 изображений на модель.

50 шагов DDPM, CFG 1,5, MSE VAE, FP32 без TF32.

Одинаковые классы и парные шумы для всех моделей.

Основной критерий: FID↓ при той же битности.

Дополнительно: sFID, IS, precision и recall через ADM.

FID снижается с 15.40 до 7.81

Модель	бит/парам.	FID↓	sFID↓
Исходная DiT	32	6,10	21,68
VQDM без KD	4,15	15,40	27,60
VQDM + KD500	**4,15**	**7,81**	**23,37**

FID ниже на 49,3% при прежней битности.

До исходной DiT остаётся разрыв 1,72 FID.

Recall снижается: $0{,}7115 \rightarrow 0{,}6770$.

Вывод: гипотеза поддерживается в проверенной конфигурации. Один фиксированный запуск не устанавливает устойчивость по seed.